AUAR 雪妃

基于 KV260 的多模型交互与执行监督系统

AMD 自主选题设计报告 V2 2026年11月2日

摘要

AUAR·雪妃以AMD KV260组织视觉感知、独立身份服务、语音交互、记忆和单轴执行。PS承担采集、预后处理、业务与显示，PL集成单个B4096 DPU和自研运动监督逻辑，Windows主机提供27B语言模型与OmniVoice语音合成。设计重点是多模型共享、结果时效、命令许可和完整回答交付。

历史固定输入对照中，YuNet与SFace路径中位耗时分别由124.02ms、520.86ms降为61.41ms、13.56ms；宽版平台使用66,960个LUT、710个DSP。后续记录已确认转轴随动、人脸KNOWN和声纹本人识别的阶段成果；新版联合演示、冷启动及长时召回仍待对应验收。接口合同Skill在本次Windows独立目录通过15项单元测试和73个模拟用例。各结果按其版本、输入与验证层级分别报告。

关键词：KV260；软硬件协同；多模型；执行监督；语音交互；可复现验证

七项要求与章节位置

AMD要求	章节	配套内容
选题背景与创新点	第1章	既有工作、应用问题与本项目贡献分开说明
设计原理与功能框图	第2章	总体、视觉、语音记忆与运动接口图
软硬件划分与接口	第3章	PS/PL/Windows分工、寄存器与数据合同
优化与性能资源对照	第4章	原始数据、样本量、前后对照与统计边界
大模型协作记录	第5章	真实可见问答、工程复盘和工具纠错分层归档
技能包提炼过程	第6章	失败来源、离线效果、使用方法和失效条件
从零复现说明	第7章	附件可执行步骤、整机输入与尚待完成的验收

1 选题背景与创新点

1.1 应用问题与设计目标

桌面交互终端需要同时处理“用户在哪里、面对谁交互、当前说什么、何时执行动作”等问题。单独运行视觉或语音演示时，模块容易各自成立；合入同一嵌入式平台后，相机与音频争用 CPU、模型任务相互等待、旧帧与旧回答迟到、显示与播放状态不同步等问题会直接影响使用体验。

本作品选择将较重的语言模型与语音合成留在局域网主机，把真实采集、视觉推理、业务状态、记忆和受监督执行放在 KV260。设计目标是形成可解释、可验证的交互链，并明确每个动作和每项性能数据所依赖的版本与条件。应用定位是桌面交互原型及教学研究平台。

需求	设计响应	验证关注点
连续感知交互对象	唯一相机源、目标轨迹与人脸身份链	有效输出频率、帧龄、未知人拒识
多个视觉任务共存	单 DPU 共享、主任务优先、可选任务准入	等待、超限、恢复与业务覆盖
交互与动作保持一致	PS 校验目标及时效，PL 独立管理执行许可	旧会话、乱序、超时及停止
自然语音与可追溯记忆	流式交付、完整播放确认、摘要校验与回收	内容正确性、取消、存储与召回
可交接与复用	配套工件、证据索引、Skill 与复现说明	新目录复现、依赖闭包及第三方执行

1.2 前人工作与本项目定位

YOLOX 提供目标检测的公开模型基础，ByteTrack 提供通过检测框关联维持目标轨迹的方法；OpenCV Zoo 提供 YuNet 人脸检测和 SFace 特征模型。本项目使用这些已有算法与模型，工作重点是目标平台适配、任务组织、接口与系统验证。[1-4]

AMD Vitis AI 提供 DPU 模型量化、编译和运行基础；官方 3.0 兼容说明列出与 2022.2 工具链的配套关系。PYNQ 提供 Overlay、DefaultIP 和寄存器访问机制，可作为接口合同生成工具的目标环境。[5-6]

既有基础	本项目实际工作	应用边界
YOLOX / ByteTrack	复用模型与关联方法，接入板端采集及目标状态	轨迹编号不等于真实身份
YuNet / SFace	等价改写、校准、DPU 编译、模板版本隔离与质量评估	公开配对结果不代替现场识别率
Vitis AI / DPU	同一 B4096 上组织三模型及 CPU 预后处理	调度逻辑位于 PS，未实现多 DPU 核仲裁
PYNQ 接口机制	从合同与 HWH 生成访问及测试骨架	当前只完成离线生成和模拟验证

1.3 主要设计特点与创新价值

第一，围绕交互任务组织计算资源。视觉主任务与按需人脸任务共享同一 DPU；数据准备、推理和业务接受分别检查，关注有效结果与等待，而不只统计模型调用次数。当前已有混合运行及恢复记录，调度策略的严格同输入收益仍需单独实验。

第二，把运动接口设计为带独立许可的事务。上层提供目标脉宽和有限租约，PL 检查会话、代次与连续序号，并在帧边界限速推进。停止和许可失效优先关闭输出。设计将感知和策略计算的波动与底层 PWM 时序分开约束。

第三，将回答交付与记忆提交相衔接。回答文本、播放确认、摘要校验和原文回收使用可追溯状态，便于检查迟到、取消与更正。已有自然到期存储证据，真实同会话摘要召回仍待完成验收。

第四，把实际失败转化为复用方法。PYNQ Skill 将“有地址窗口但缺寄存器元数据”“完成标志迟于超时”等问题固化为检查、反例和独立示例，形成可交给其他工程使用的离线工具。

2 设计原理与功能框图

2.1 系统总体结构

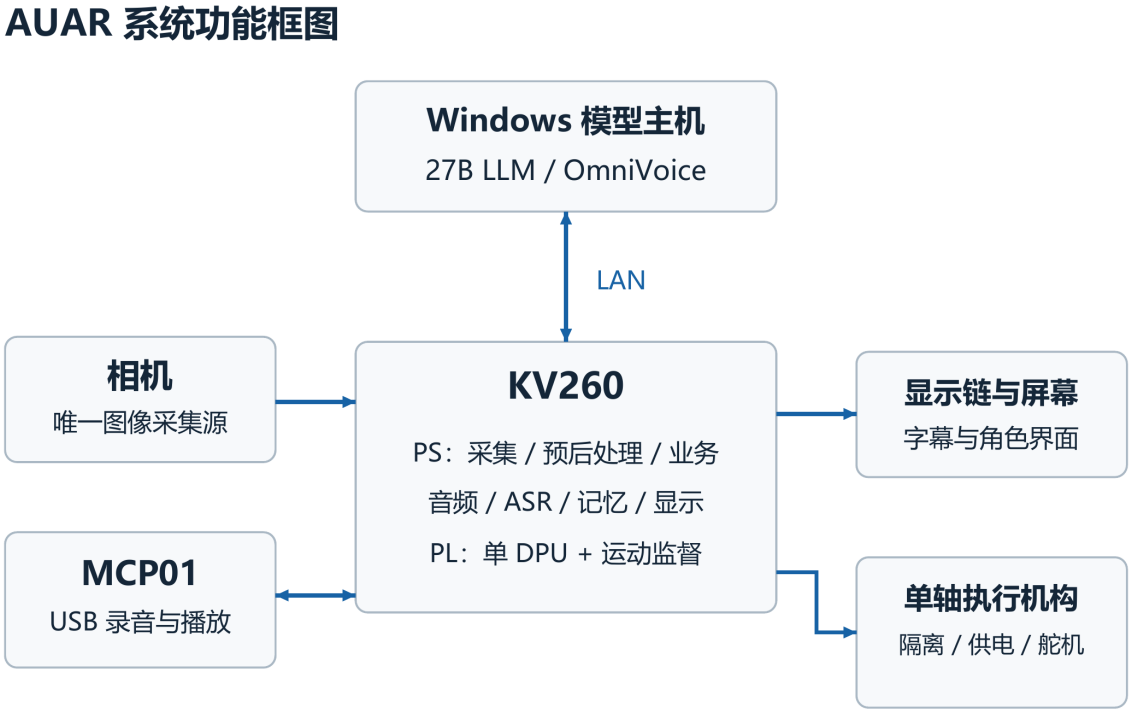


图1 系统总体功能框图 运行端与外设接口

相机与 MCP01 接入 KV260。PS 负责唯一采集、预后处理、视觉业务、音频前端和语音识别，通过局域网请求 Windows 的语言模型与 TTS，再在板端完成字幕、角色状态和播放。PL 中的 DPU 计算视觉网络子图，自研监督 IP 接受经 PS 检查的运动事务。

系统具有两条相互配合的路径：感知交互路径将图像、语音和身份状态转为有效回答；执行路径将当前目标转为有边界的运动请求。开发链使用 Ubuntu 完成 RTL/平台构建、模型编译与文件校验，不参与日常交互推理。

2.2 视觉、跟踪与身份原理

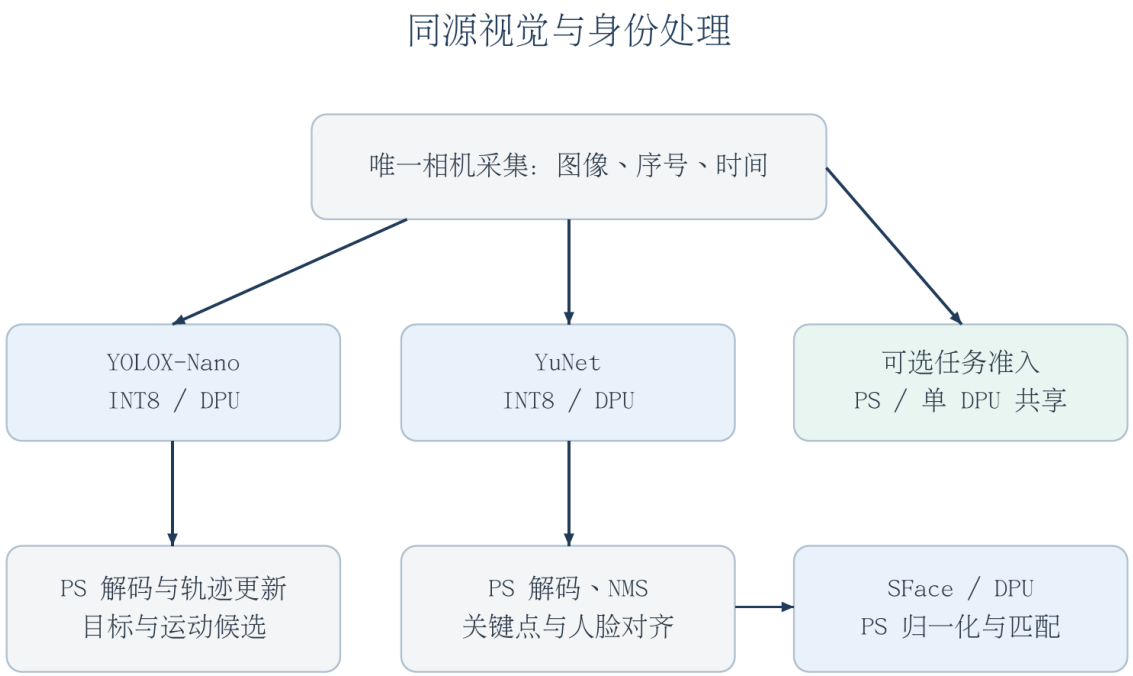


图2 视觉处理与身份链；蓝色为 DPU 网络计算，灰色为 PS 处理

相机采集后保留源帧序号和时间信息。YOLOX-Nano 提供目标检测结果，跟踪过程维持目标轨迹；YuNet 提供人脸框及关键点，PS 完成解码、NMS 和对齐，SFace 输出身份特征，再由 PS 归一化、匹配并更新业务状态。身份模板按特征模型版本隔离，匹配不足或歧义时保留 UNKNOWN。

部署记录中的三个网络均为 INT8 DPU 工件，每个网络包含一个 DPU 计算分区；板上共享的是单个 B4096。图像编码、后处理、对齐和身份匹配仍消耗 CPU。模型与预处理、输出端口顺序及缩放因子需要配套。[V04-V07、V19]

模型	输入 NHWC	工件大小	部署 SHA256 前缀
YOLOX-Nano	1×416×416×3	2,127,303 B	def64abdeeccbd020
YuNet	1×320×320×3	576,254 B	54d348bfeee01756
SFace	1×112×112×3	10,796,375 B	12b2ff5c7de15713

2.3 语音交互与记忆原理

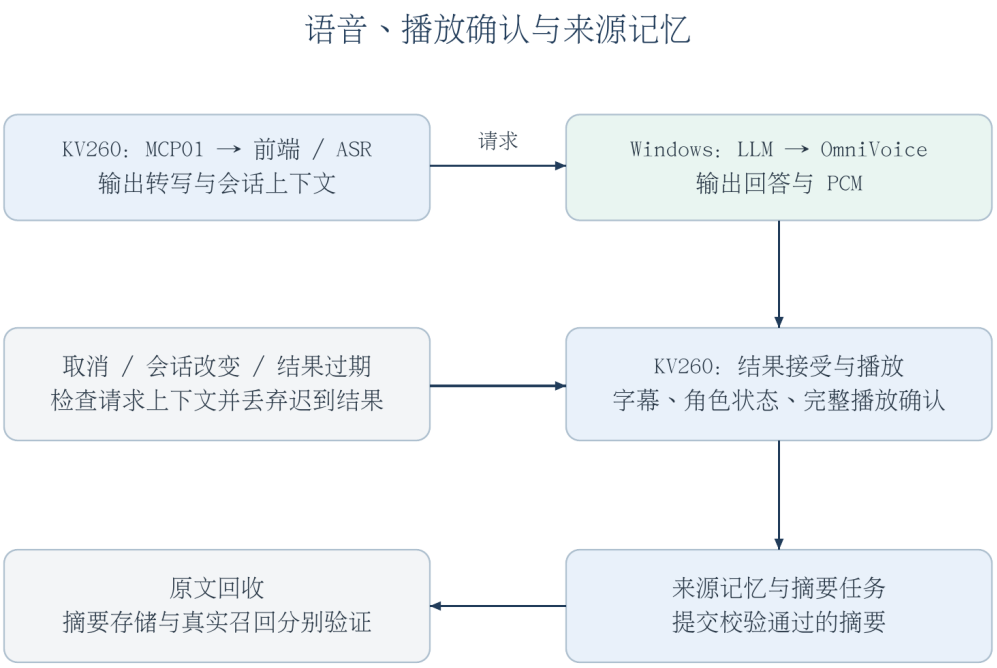


图3 板端语音、主机回答、播放确认与记忆处理流程

较新的板端业务记录采用板端音频前端与 ASR，Windows 保持现有 27B 语言模型和 OmniVoice 推理。板端将转写、身份及会话上下文组织为请求，主机返回有效回答和音频；板端负责播放、字幕及角色状态。较早 Windows ASR 结果只用于对应历史链路比较。

一次请求应关联会话及请求标识。取消、会话切换和迟到返回需要在结果接受处检查；被取消或未完整交付的回答不直接作为完整已播历史提交。记忆处理将原文保存、摘要任务、有效摘要与回收状态分开，便于追溯来源与失败重试。[V10、V29、V31]

人脸与声纹按独立服务工作。保存进度已记录人脸KNOWN和声纹本人三次独立录音识别的现场确认；普通聊天首句自动识别接入仍在推进。人脸与声纹跨模态关联已取消，不列入本版交付和联合演示的前提。[V29]

2.4 单轴执行监督原理



图4 PS检查与PL命令许可 源帧时效和命令租约分别处理

PS 根据当前目标及帧龄计算请求；PL 侧使用影子字段接收会话、代次、序号、目标脉宽和租约，再在 COMMIT 时进行一致性判断。BIND 建立上下文，REFERENCE 写入经外部确认的控制参考，ARM 开放命令接受，COMMIT 更新目标与租约，STOP 关闭输出许可。REFERENCE 是控制参考，不提供实际角度测量。

宽版 RTL 使用 100 MHz 控制时钟和共享约 1 μs 时钟使能，PWM 帧周期为 20,000 μs，目标范围为 500-2500 μs，12 位字段保存脉宽，帧边界每次最多推进 4 μs。上述值来自对应实现，实际机构零点、角度、负载及允许行程另行标定。[V20-V23]

2.5 功能范围与实测范围

功能	已有证据	本稿采用的表述
联合 FPGA 与模型共存	构建、时序、配对工件及历史上板记录	已有阶段实现与运行证据
三模型视觉与独立身份	固定向量、公开评测、人脸KNOWN及声纹本人确认	各自报告验证范围；不加入人脸与声纹关联
语音、字幕与角色显示	两轮真人完整播放及后续UI就绪回执	两轮属于先前启动；新版联合演示另验
单轴随动	用户现场确认跟随正常、无卡顿	功能行为验收已通过；精确角度和载荷仍无量化结论
摘要与原文回收	自然到期存储检查	STORAGE_PASS_RECALL_PENDING
VLM、视觉说话人及声纹 DPU	方案、候选或待适配记录	不计入本稿已验收功能

3 软硬件划分依据与接口设计

3.1 平台选择与工具版本

目标平台为 KV260，宽版实现报告声明器件为 xck26-sfvc784-2LV-c。项目沿用已有 Vivado/Vitis/PetaLinux 2022.2 与 Vitis AI 3.0 环境，原因是已有参考平台、系统和模型编译链围绕这一组合验证，官方兼容说明也给出该组合。依据 AMD 指南，采用其他工具版本应说明原因并提供可复现脚本。[5、7、V01-V03]

该选择不表示任意同名镜像或 DPU 文件均可互换。最终 release 需要固定源码、实际 DPU fingerprint、模型目标、运行时、BIT/XSA/DTBO/XCLBIN 及设备树映射。

3.2 任务划分及判断依据

任务	执行位置	划分依据	主要代价与约束
网络卷积等子图	PL / B4096 DPU	使用现有 INT8 推理硬件	受算子、形状和目标指纹约束
采集、预后处理及身份匹配	PS / Linux	与设备、动态目标和业务状态关联	CPU 调度及内存访问影响长尾
多模型准入与等待	PS 调度器 / 原生运行层	单 DPU 统一所有权，主任务优先	提交前估计无法给出全局硬实时保证
PWM 与命令许可	自研 PL 监督 IP	需要独立租约、帧时序和停止逻辑	需同时验证 RTL、约束及真实电气输出
音频前端、ASR、存储和显示	PS / Linux	保持板端真实输入与业务一致	正常业务短窗 CPU 已接近满载
27B LLM 与 OmniVoice	Windows GPU 主机	保留现有模型质量与主机运行环境	网络、模型排队、显存与取消需配套
构建、量化与证据整理	Ubuntu 开发机	工具链及已有工程位于开发端	需消除历史绝对路径依赖

3.3 硬件与外设接口

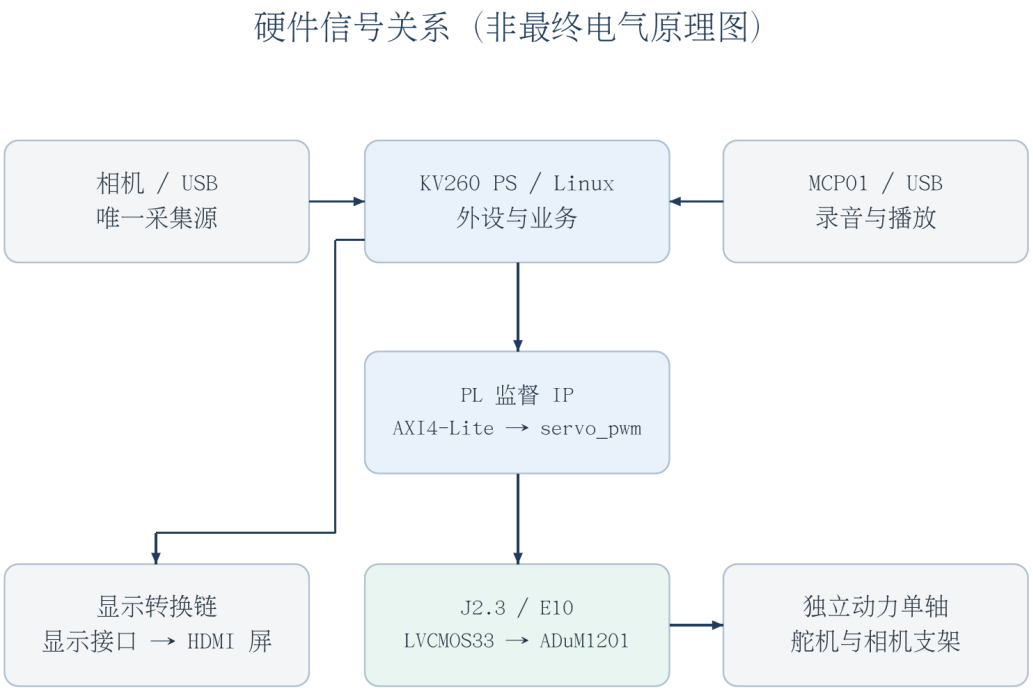


图5 外设与执行信号关系示意；用于解释模块关系，不替代最终电气原理图

相机和 MCP01 通过板端外设接口接入；显示通过现有显示转换链连接屏幕；网口连接 Windows 主机。运动信号在宽版 XDC 中约束为封装脚 E10、LVCMOS33；B03参考资料将E10映射为J2.3。封装脚、连接器针号和模块端子是三类编号，实物载板版本与针1方向需要另行确认。现有方案记录使用 ADuM1201 和独立舵机供电，最终接线、两侧电源/地及实际隔离关系仍须用实物原理图核对。[V20-V22]

控制器读回的 PWM 脉宽表示指令状态。它不能代替角度传感器、示波器测量或机构行程验证。附件wiring已给出资料核对版电气接线图、整机外设连接图及W01-W11逐线表，保留供电方案值和现场待核项。实物照片、实际供电值、模块端子和机械装配图需随最终实物记录补齐。

3.4 PS-PL 寄存器接口

宽版准备脚本将自研 IP 的 AXI4-Lite 地址窗口设为 0x80080000，范围 0x1000。下表为 VSRV/2、build 0x10282601 对应 RTL 的相对偏移；使用前必须核对真实映射与版本，不能套用于其他固件。[V20-V21]

偏移	字段	访问与语义
0x000 / 0x004 / 0x008	ID / ABI / BUILD_ID	只读；ID=0x56535256，ABI=2，BUILD_ID=0x10282601
0x00c	flags / reason	只读；active、armed、referenced、bound 及拒绝原因
0x010 / 0x014 / 0x018	shadow session / epoch / seq	影子上下文；提交时共同校验
0x01c / 0x020	shadow width / lease	目标脉宽 μs；租约 ms
0x024	command	BIND、REFERENCE、ARM、COMMIT、STOP、QUIESCE
0x028 / 0x02c / 0x030	ack_seq / width / lease_left	接受序号、当前指令脉宽和剩余租约
0x034 / 0x038	session / epoch	当前绑定上下文
0x03c / 0x040 / 0x044	shadow reference / reference / target	控制参考、已接受参考及目标脉宽

有效 COMMIT 要求已绑定、已参考、已 ARM，影子会话/代次匹配，序号恰为 ack_seq+1，脉宽在允许范围内，租约满足 4-500 ms。命令写入得到 AXI 应答后，软件还须检查业务 reason 和 ack_seq；AXI 总线成功不等于命令已生效。

STOP、租约失效及完成 QUIESCE 会关闭许可并使原绑定失效。QUIESCE 允许正在输出的脉冲自然结束；显式 STOP 具有直接关闭语义。源帧时效由 PS 检查，当前 PL 租约从接受命令起计时，PL 并未验证源帧的绝对截止时间。

3.5 视觉与交互数据合同

接口	关键输入	关键输出	接受条件
相机→视觉	图像、源序号与时间	检测框、轨迹及人脸候选	保持同源关联，旧结果不覆盖新状态
人脸→身份	对齐图、特征模型版本	特征、匹配分数、KNOWN/UNKNOWN	模板版本及阈值配套，歧义保留未知
视觉→运动服务	有效目标、图像位置及时效	有限目标脉宽与租约	上下文有效、单写入者、未过期
板端→Windows	转写、会话与请求上下文	回答、音频及状态	当前请求可接受，取消与版本匹配
播放→记忆	完整播放确认、回答来源	历史提交和摘要任务	确认交付后提交，失败保留可追溯状态

3.6 时钟、复位与异常处理

监督逻辑在对应 AXI 时钟域运行，采用时钟使能生成时间基准，避免另造低频门控时钟。复位时输出与许可关闭。平台还有 DPU、视频及显示时钟，应随最终 clocks、timing、CDC 和 DRC 报告一并提交。

独立审查已记录 setup/hold 失败端点为0、路由错误为0，同时保留六类 DRC warning 和 6 个 no_input_delay、2 个 no_output_delay 端点。WNS 接近0，当前结果只覆盖已声明约束；板外 PWM、电源及机械测试仍需相应证据。[V03]

4 优化过程与性能、资源对比

4.1 测量口径

本章将固定输入模型对照、模型任务质量、静态实现资源和正常业务观察分开。每张表注明输入、样本量或版本；正文的中位数与 P95 使用历史原始结果中的定义，本轮未重新采样。已有结果不混合成“最终整机平均性能”。

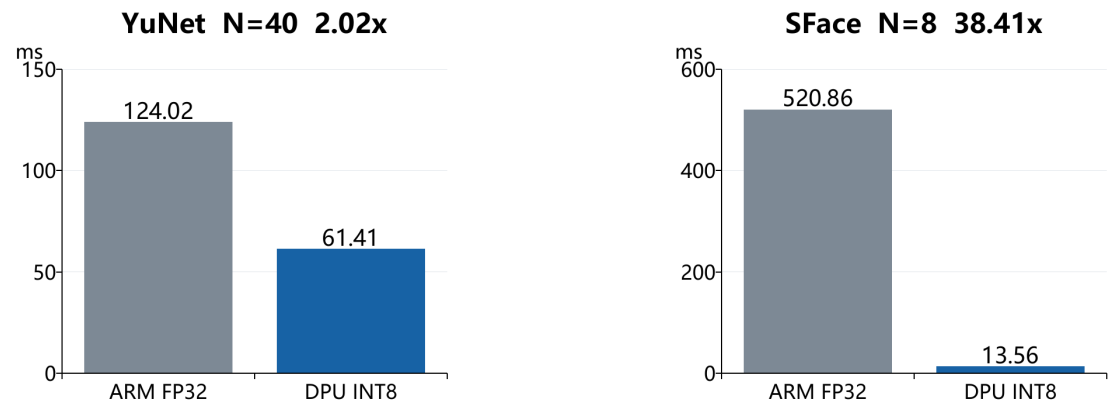
对完整视觉路径，可把耗时分解为采集/排队、预处理、DPU 等待与执行、后处理和业务接受。对语音路径，可分别记录发言结束、ASR 完成、首正文、台词就绪、首 PCM 和板端播放开始。软件事件与扬声器真实首声属于不同测量量。

4.2 模型迁移：从 ARM FP32 到 DPU INT8

迁移先检查算子与数值，再完成代表性校准、目标编译和固定输入板测。模型外处理保留 PS，运行器以 VART 返回的端口顺序组织缓冲区。早期曾因 XIR 集合顺序与 VART 端口顺序不一致发生错误，修正后增加了顺序互换回归。[V04-V07]

路径与样本	ARM FP32 中位 / P95	DPU INT8 中位 / P95	中位加速比
YuNet，40 次固定输入，含预后处理	124.02 / 147.60 ms	61.41 / 64.75 ms	约2.02倍
SFace，8 次已对齐固定人脸，含输入输出转换	520.86 / 627.78 ms	13.56 / 26.60 ms	约38.41倍

该对照同时改变执行硬件与数值精度，收益不能全部归因于量化。迁移复用同一 DPU 位流，不新增 DPU 核；软件模型切换本身没有新增静态 LUT/DSP/BRAM。两项短测不能表示 Windows 主机或整机问答的加速比。[V04-V05]



两个子图纵轴独立；对照同时改变硬件和数值精度，不代表整机问答加速比。

图6 固定输入路径中位耗时对照 两个子图使用独立纵轴

4.3 量化质量及参考结果

SFace 使用256个身份的公开样本校准，校准与评测身份分离；2,200对用于选阈值，独立测试为1,000对，含500正对与500负对。两个精度路径各自在训练配对上选阈值，测试结果如下。[V06]

指标	FP32	INT8 量化模拟
独立测试准确率	98.8%	98.8%
误接收 / 500负对	0	1
误拒绝 / 500正对	12	11

总体准确率相同的同时，错误类型发生变化。该1,000对评测在主机上进行，另有4组实板向量与量化参考逐整数一致。现场身份阈值与公开评测阈值不同，因此不能把98.8%直接写成整机现场身份准确率。

YuNet 在256张身份独立测试图、阈值0.9时，FP32参考检出294张脸，INT8匹配293张，匹配框 IoU 中位0.97428，关键点平均误差中位约1.45像素。这里使用FP32输出作参考，尚不是人工标注真值上的检出率或AP。另有4组输入共399,500个INT8输出整数与主机参考一致。[V04、V07]

YOLOX-Nano 当前使用既有INT8工件。项目场景的独立标注集、FP32/INT8 mAP及误检/漏检对照仍待补，不从约10Hz业务频率推断检测准确率。[V19]

4.4 多模型调度与原生执行

固定预编码输入下，同进程三模型切换阶段执行 YOLO 40次、YuNet 20次、SFace 8次，配置频率为10/5/2Hz，100ms周期超时为0。该阶段三模型 submit/wait 中位数分别为6.78、2.36、8.41ms。[V05]

实时链路随后经历过排队、GIL重获与可选模型超限等问题，形成通知等待、独立取消、预算准入、超限回退及原生运行层等修订。已有主任务与可选任务共存记录，但前后观察背景不同，不能据此给调度策略计算严格加速比。[V17]

后续公平实验应固定同一release、同一输入回放、目标人数与任务集合，对照基线和当前策略，报告主任务P50/P95/P99、有效结果频率、帧龄、等待、超限、丢弃和身份覆盖。尚无结果的项目在表中保留待测，不用预估填充。

4.5 宽范围监督：接口能力与静态资源

宽范围升级将11位位置字段扩展为12位，同时配套 RTL、原生接口和上层配置，以保存2500μs；若仍截为11位，2500会变为452，属于接口一致性错误。两版资源来自同类联合平台的布局布线报告，差异包含实现工具的布局变化，不能按差值反推单个 IP 的精确资源成本。[V01-V03、V19]

指标	10月23日联合窄版	10月28日联合宽版	解释
LUT	66,969（57.18%）	66,960（57.17%）	全平台差9，不解释为独立IP收益
FF	124,189（53.02%）	124,192（53.02%）	全平台，增加3
BRAM Tile	93.5（64.93%）	93.5（64.93%）	持平
URAM	56（87.50%）	56（87.50%）	持平
DSP	710（56.89%）	710（56.89%）	持平
CLB站点	13,968（95.41%）	13,968（95.41%）	与 LUT 利用率是不同口径
WNS / WHS	0.001 / 0.000ns	0.001 / 0.000ns	已约束路径
setup / hold失败端点	0 / 0	0 / 0	静态时序结果

宽版独立审查确认200,473条可布线网络全部布通，路由错误0；没有把DRC warning写成0。数字脉宽能力为500-2500μs，但最终机械零点与±90°行程未完成验收。历史新boot初始化曾出现实体异常并中止，其失败记录保留。11月2日后续交接已记录用户对随动正常、无卡顿的现场确认；这一功能行为验收不等于机械零点、精确角度或载荷测量通过。[V03、V17、V29-V30]

4.6 回答交付与资源优化

结构化输出优化把有效台词置于较早可消费的位置，保留业务字段与校验。旧/新格式各4次的模型阶段中位数如下；回复措辞和长度有变化，该小样本用于阶段定位。[V08]

指标	原格式	短字段格式
首正文	1754.07ms	1344.27ms
台词字段就绪	2762.88ms	2287.70ms
完整结构结束	4737.30ms	3745.70ms

LLM/TTS共存优化还实现了资源观测、准入、租约、有界排队及取消接点。既有GPU资源策略和测量属于原平台；后续5090主机的原模型与LAN部署已有通过记录，保存健康状态正常；旧平台的预算和性能比仍只适用于原试验，不能移作新主机的优化收益。[V15、V29]

4.7 正常业务资源观察

2026年10月31日30.004秒观察窗中，板端由播报恢复自动聆听，视觉与三个模型计数有推进；跟随关闭。下表反映该实例的资源分布。[V09]

项目	结果	统计定义
CPU平均 / 1秒峰值	78.65% / 96.98%	四核总容量为100%，排除idle/iowait
DPU平均 / 1秒峰值	6.27% / 8%	驱动CU任务忙时
内存平均占用	1.466GiB，38.20%	MemTotal - MemAvailable
最低可用内存	2.360GiB	同一观察窗
GPU	已观察到活动，百分比未取得可信结果	中断及渲染计数推进；原接口恒0

CPU与DPU忙时的差异说明该窗口中压力更多落在PS及业务侧，不能直接推算剩余并发容量。GPU/XRT/CMA属于共享系统内存的不同统计，不与总占用再次相加。长稳、温度、降频和全功能并发仍待补测。

4.8 保存进度与验收范围

以下状态依据2026年11月2日的保存进度与各模块回执摘录。它们记录不同层级的验证，不拼接成一次同版本全功能验收。保存进度的总体结论为：声纹本人识别已现场通过，普通聊天首句自动识别接入中；开机恢复剩1项离线返修及上板验证；性能后测待交接。[V29-V30]

模块	保存记录中的结论	证据
本机模型与LAN	原模型/LAN部署已通过；08:57本机健康正常	V29
板端业务/角色UI	身份窗口08:52保存回执确认运行正常	V29
视觉感知	相机/DPU工作；人脸登记及KNOWN已有现场确认	V29
基础语音对话	已有两轮真人完整播放实测；新版联合轮次待重验	V29
转轴跟随	用户最新实物验收通过：转轴正常、无一顿一顿；调参排查收口	V29
身份与语言协同	声纹登记及本人三次识别已通过；聊天首句自动识别接入中	V29
记忆	板端时间轴及摘要已部署；现有记忆链与长时召回待联合验证	V29
板端CPU优化	GTK优化已发布；相机候选未上板；没有新增性能后测	V29
开机恢复与全流程演示	新修订50项定向检查通过；独立复核剩1项返修，未部署	V29

转轴随动的功能行为验收已经收口，保留现有实现和参数。后续开机恢复和其他模块维护不自动扩大这一验收结论。独立人脸和声纹能力分别表述，跨模态关联不作为待做功能。普通聊天首句自动声纹识别、同条件性能后测、现有记忆长时召回、冷启动和新版联合演示仍按各自回执验收。[V29-V30]

4.9 两轮完整播放的软件时延

已有两轮真人交互的完整播放回执；下表读取同一份原始JSON。起点为录音完成事件，终点为每0.25秒采样观察到的软件SPEAKING状态，不是最后一个发音音节到扬声器物理首声的声学测量。[V31]

阶段或事件	第1轮	第2轮
ASR	1092.74 ms	1394.85 ms
上下文准备	25.94 ms	128.74 ms
LLM RPC	1939.99 ms	1833.20 ms
TTS RPC	765.95 ms	838.40 ms
worker起点至首音频入队	4328.19 ms	4591.30 ms
录音完成至观测SPEAKING	5044.43 ms	5285.39 ms

两轮完整播放确认均已提交，记录中的当前轮欠载包和背压等待为0。样本只有两个短轮次，不据此给出可靠P95/P99、固定响应保证或新版联合性能结论。RPC耗时包含传输与服务等待；累计guard处理与后续音频事件重叠，不能把全部阶段数值直接求和当作首声时间。[V31]

5 大模型协作记录与自我纠错

5.1 协作方式与人工职责

AI协作用于需求拆解、代码与脚本草拟、错误定位、测试设计、报告整理和方案比较。人工负责确定应用目标、冻结模型与质量约束、选择变更、核对原始输出、安排实板观察和接受/否决方案。执行结果由对应源码、工件、日志及数据支持。

现有《AI辅助工程开发与交付记录》已整理五个工程案例和38项来源索引。五个历史工程案例保留为基于源码和日志的复盘；原始逐轮问答与准确模型构建版本按实际留存情况登记。第5.5节另列本对话真实可见提示、答复和工具纠错，附件使用不同记录类型标识，不将复盘改写成历史逐字问答。[V15-V16、V33]

案例	AI协作形成或修改的文件	观察、判断与纠错	已有验证
FPGA联合工程	visual_servo.sv、prepare.tcl、implement.tcl、export_resume.tcl	原项目导出失败后从同一已路由DCP恢复导出，核对配套载荷	4套RTL、204项控制器、18项C模拟及独立实现审查记录
DPU移植	rewrite_sface_v2.py、reconstruct_yunet.py、量化/编译/向量脚本	区分兼容性、编译、执行一致性与任务质量；修正端口顺序	公开评测、固定向量实板及三模型切换
结构化回答	dialogue_stream.py及配对测量脚本	提前交付有效台词，继续保留完整字段和取消	阶段测量与对应版本播放验收
LLM/TTS共存	gpu_coordination.py、资源配置及语音生命周期接点	比较排队、常驻与冷暖加载；被否决候选不算正式收益	历史资源测量及合并回归
记忆与回收	board_memory.py、board_memory_policy.py	校验摘要并提交后回收原文；存储与真实召回分别验收	自然到期存储检查，召回待补

5.2 可追溯的可见问答摘录

现有附件保存一条与工程范围调整有关的真实用户指令：

> 我这几天做了大语言模型优化啥的，可以把这个替换成C，你看看win里面语音模型的整个做的东西，你可以看看

对应AI回答开头摘录：

> 可以替换。我已查看 Windows 同步过来的主要源码、优化报告和测试记录，整理了 73 份来源，并把 C 的规划改为：

后续处理将C包规划调整到LLM输出、资源、记忆和语音工程，保留原异步验证子模块。该记录证明资料审阅与范围调整；五个历史开发案例仍需各自原始问答附件。[V16]

5.3 实际自我纠错示例

PYNQ Skill首轮15项单元测试出现1项失败：完成标志在200ms才被观察到，而合同超时为100ms；原逻辑先检查完成，再检查超时，错误接受了迟到结果。修正为读回后先检查观察时刻是否超时，再判断完成，随后15项全部通过，并保留此反例。[V12-V13]

这一纠错可追溯到具体失败、代码修改和验证结果。其证明范围是软件轮询的观察时间，不能中断已经阻塞的MMIO操作，也不能证明硬件最坏执行时间。

5.4 可重复使用的协作工作流

协作流程为：提供明确任务和现有证据→要求AI标出假设与适配边界→人工核对接口及候选变更→先验证数值/软件反例→需要时在原设备窗口完成实板测试→接受或回退→冻结源码、工件和证据→提炼Skill。

下一次新增AI协作案例应同时归档：原始提示词、关键回答、被发现的问题、人工判断、实际修改、验证命令/输入、原始结果和版本清单。无法取得的历史内容标记缺失，不从代码反向编造。

5.5 可见问答与文档生成纠错实录

案例AI06来自本对话可见消息和实际工具反馈，日期为2026年11月2日，工具为Codex；具体模型构建版本未记录。附件ai_collaboration/wiring_case_verbatim.json保留摘录、修订及验证来源。[V33]

用户提示摘录：

> 这个怎么做，按照我这个盘里面的资料，你可以帮我做一下么

AI公开答复摘录：

> 我会按盘里的接线资料和 FPGA 引脚约束，先做一份可放进报告的接线图和逐线接线表。资料能确认的内容会直接标出，尚未核实的实物端子会标为“待核对”，重点处理旧图 H12 与宽版约束 E10 的差异。

证据核对后采用宽版XDC中的E10；B03的J2.3映射与实物端子待核状态分别标注。首次PDF绘制把颜色名称white交给HexColor，实际工具报错如下：

```
ValueError: invalid literal for int() with base 10: 'white'
```

实际修正为允许颜色名称的转换函数：

```
c.setFillColor(colors.toColor(fill))
```

随后的图片审阅还发现电源域标题压到导线、W10/W11标签过近以及端口文字碰线，分别移位修订。最终三页PDF逐页通过检查，两个SVG可解析，W01-W11与逐线表一致。此案例证明的是资料核对、图纸生成与工具反馈纠错，不扩大为FPGA算法设计的原始协作记录。[V33]

6 技能包的提炼、验证与边界

6.1 交付对象与内容

当前独立离线初版为 pynq-contract-testgen。输入包括AXI4-Lite uint32接口合同、HWH元数据、测试向量及独立模拟/参考模块；输出包括PYNQ访问驱动、测试骨架、合同检查报告和使用说明。包使用Python标准库，默认执行模拟路径，不要求安装PYNQ即可完成离线示例。[V12-V13]

组成	作用	来源
合同与HWH检查	校验实例、窗口、偏移、权限及完成语义	实际HWH存在地址窗口但REGISTER为0的观察
代码/测试模板	把接口约定生成可审查代码	手工接口与元数据不一致问题
超时反例	防止迟到完成绕过观察期限	首轮测试真实失败
加法与CRC两例	改变布局、完成位与读清除语义	检查生成器是否依赖单一题目
复现与校验清单	在新目录核对源字节并重跑示例	工程交接与路径依赖经验

接口合同到验证结果



同一生成器用于加法和CRC两类布局；黄金参考与模拟实现独立。

本次验证层级为离线生成与模拟。真实PYNQ、跨板和整机复现分别记录。

图7 接口合同到生成代码与参考比对的工作流

6.2 从失败到规则

第一次观察是元数据不完整。真实工程HWH中自研模块的REGISTER元素数为0，表明地址窗口与完整寄存器描述不是同一种信息。工具因此区分MATCHED、INCOMPLETE和冲突；缺少定义时不能凭空生成register_map字段，已知冲突不能绕过。

第二次观察是完成判定顺序。软件需要先判断观察时刻是否超时，再接受完成标志，防止“最终完成”覆盖“已错过期限”。对应反例和修正保留在包中。

第三次观察是单个示例不足以证明复用。加法例与CRC例更换实例、寄存器偏移、完成位和读清除语义；算法分别放在独立模拟和黄金参考中，生成器核心不按算法分支。

6.3 已验证效果

项目	保存的结果	层级
单元测试	15项通过	离线软件
加法示例	36例通过	生成代码 + 模拟IP + 黄金参考
CRC32示例	37例通过	模拟采用逐位实现，参考使用zlib
新目录复现	源SHA一致，测试与示例通过	同一助手换目录复现
解压复现	归档CRC/SHA和73例通过	归档可执行性
本次Windows Python 3.12.14复跑	15项单元测试、加法36例、CRC37例通过	独立目录，原Skill源码未改
真实PYNQ / 跨板 / 非作者复用	未验证	不计入现有通过项

本次复跑的是同一套已有用例，增加了Windows环境可执行性的证据，不增加用例覆盖。原始日志、新目录输出及软件环境保存在attachments/validation；board_verified与pynq_imported均为false。[V32]

加法按uint32模2^32，CRC采用CRC-32/ISO-HDLC并明确四个小端字节的输入规则。软件运行耗时不作为PL加速性能。当前初版不能据此宣称已满足PYNQ跨板加分验证。[V12-V13]

6.4 使用范围与失效条件

首版限定32位标量AXI4-Lite访问。DMA、AXI-Stream、缓存一致性、中断、64位寄存器及复杂并发接口不在已验证范围内。硬件模式必须另有真实且匹配的位流/HWH、兼容PYNQ环境与目标板。合成HWH示例只用于解析及模拟，不能用于宣称硬件通过。

6.5 其他技能包规划

执行监督、DPU适配/调度和LLM语音/记忆优化已有提炼文档；原A/B/C三包仍需按各自状态完成交付。声纹DPU适配尚待确定，不与已完成的三个视觉模型合并计算。正式提交可先交付已实现的离线Skill和明确范围的工作流/踩坑清单，再由实际复用证据扩展声明。

7 从零复现说明与交付状态

7.1 包内组成与复现层级

附件为本报告的可核对材料和离线Skill，不将其称为完整整机源码发布。下表分别说明可执行的离线层级与整机层级；整机层级仍需最终工程输入、配套release与目标设备验收。

层级	输入与入口	完成判据
文档与证据核对	source_index.json及attachments/evidence	每个归档证据文件SHA一致
离线Skill复现	reproduction/reproduce_offline.py	15项单元、加法36例和CRC37例通过；board_verified=false
FPGA完整构建	完整平台工程、参考DCP、IP仓库与2022.2工具链	新目录构建、导出和配套检查通过；本附件未完成该层级
模型重建与板端软件	固定模型来源、校准数据、arch及最终源码清单	量化/编译/参考比对与同版部署分别通过
最终整机复现	外设、板卡、主机和统一release	现场按说明完成业务、恢复与持续运行验收

7.2 在空目录复现包内材料

1. 将附件ZIP解压到新的工作目录，进入包含README.txt、source_index.json、skill和reproduction的目录。

2. 准备Python 3.8或更高版本。离线入口只需标准库，不安装PYNQ、不调用模型服务，也不加载位流。

3. 在工作目录执行以下命令；结果目录必须尚不存在。Linux可将python改为python3。

```
python --version
python -B reproduction/reproduce_offline.py --out ../auar_verify_01
```

4. 检查新目录summary.json的status=PASS，以及examples中的adder=36例、crc32=37例。单元测试原始输出见unit_tests.log，示例输出见examples.log及examples子目录。

5. summary中的board_verified和full_system_reproduced应保持false。这两个字段区分离线包可执行性与实际板卡/整机验证，不用离线PASS替代板测。

7.3 换题目使用Skill

在skill/pynq-contract-testgen目录提供自己的contract.json、真实或明确标识的HWH、输入向量与独立参考结果。只修改这些输入，保持生成器核心不变。先核对寄存器名称、偏移、访问权限、启动与完成语义，再生成驱动和测试骨架。

```
python -B scripts/generate.py --help
python -B -m unittest discover -s tests -v
```

已有加法器和CRC两个实例改变了布局、完成位和读清除语义。真实PYNQ模式需要匹配的bit/HWH、相应环境和已核对的硬件；合成样例不能进入硬件模式。具体参数和失效条件见Skill自带readme.md与contract_format.md。[V12-V13、V32]

7.4 整机复现的必需输入

输入集合	应固定的内容	当前状态
工具链	Vivado/Vitis/PetaLinux 2022.2、Vitis AI 3.0及原IP版本	历史配套关系有记录；需在重建环境确认安装与许可
参考平台	source_routed.dcp、完整BD/RTL/XDC、repos.txt与IP源码	历史DCP为125,094,047B；本附件不含该DCP及完整IP仓库
配套输出	同次BIT/XSA/DTBO/XCLBIN与设备树	阶段证据已归档；最终release仍须统一
视觉模型	固定来源、预处理、校准/测试划分、arch与xmodel SHA	保留V19的模型身份；不能自动换用公开库最新默认文件
板端业务	实际应用380组件、独立相机/控制器、原生库、配置与服务	以最终配套清单收拢，不任选早期aura目录替代
Windows模型服务	27B/OmniVoice版本、运行库、外部模型路径与LAN配置	已有部署验收；旧平台性能和预算不迁作新成绩
实物	载板版本、相机、MCP01、屏幕、供电与舵机线序	接线资料版已提供，实物核线和型号记录另补

历史构建脚本要求的参考DCP SHA256为ac5f85a14eee133b56e06a514f37e3e8db30b2ae4d16a5490b79b926a07bb77e。完整重建前须取得这一输入，或先验证一条不依赖它的源码重建路线。只拿到脚本和综合报告不等于构建输入齐全。[V14]

7.5 FPGA构建步骤

1. 在Ubuntu新工作区准备完整平台工程与已核对参考DCP，固定工具版本、IP仓库、RTL/BD/XDC和输入SHA。

2. 将原构建入口中的VIVADO、REFERENCE、平台输出和IP路径映射到该工作区，保存修改差异和新的输入清单。V14为历史入口证据，其绝对路径不能直接在其他机器上使用。

3. 先执行tb_wide、tb_servo、tb_pulse_guard和tb_nominal四套RTL验证，再按prepare、implement顺序完成平台构建。

4. 归档utilization、clocks、timing、check_timing、route、DRC，按需要检查CDC；记录警告、外部时序缺项与失败，不以单个WNS代替全部约束完整性。

5. 从同次路由结果导出配套工件，核对XSA嵌入载荷、位流、DTBO/XCLBIN、IP ID/ABI/build与模型目标。独立验证成功后再安排目标板部署。

7.6 模型和软件准备步骤

1. 按V19模型清单取得固定版本YOLOX-Nano、YuNet和SFace，保留来源、许可与SHA。公开仓库会更新，复现应选择经过本项目验证的工件，而不是仅按同名最新文件替换。[3-4、V19]

2. 固定B4096目标fingerprint 0x101000056010407及真实arch.json，使用项目保留的等价改写、量化与编译脚本；校准、选阈值、独立测试身份保持分离。

3. 依次验证浮点等价、INT8任务质量、编译接口和实板固定向量。VART端口顺序、输入形状、缩放因子与预后处理应配套。

4. 按最终应用、相机、控制器和原生库清单准备板端文件与服务。Windows准备相应LLM/TTS环境；大语言模型权重位于项目共享目录之外，使用明确的外部路径配置。

5. 在各自设备维护流程下验证服务就绪和LAN请求。新启动需要建立新的上下文与实际配套关系，不沿用旧进程和旧启动的绑定凭据。

7.7 最终运行和验收步骤

在统一release上记录启动、相机有效帧、独立人脸/声纹状态、录音、ASR、回答、完整播放、字幕和记忆落盘。随后在同一合法会话自然超过五分钟后追问，记录摘要状态与真实回答，单独验证长时召回。

转轴按用户已经验收的实现和参数保留，不把继续调参作为本报告的复现前提。若申报机械角度、精度或载荷指标，应另有相应测量。冷启动、长期运行、网络异常与取消恢复按最终版本分别记录；跨模态关联已取消，不新增为联合演示要求。[V29-V30]

7.8 当前证据与下一次补录

项目	当前可确认结果	仍需要的证据
本包离线执行	本次Windows 15项单元与73例通过	陌生人员独立复用可另录
AI协作	可见原话摘录、实际工具纠错与五项工程复盘	核心开发历史逐轮原问答、准确模型版本和个人分工继续归档
Skill	合同/HWH检查、生成与模拟路径可执行	若申报PYNQ通用加分，补真实PYNQ/跨板或独立复用证据
完整重建	参考脚本、接口及阶段工件证据已整理	参考DCP/IP等完整输入与新目录完整构建日志
整机最终结果	分模块阶段通过与两轮历史播放数据	新版联合演示、同条件后测、长时召回、冷启动与持续运行

本包的离线成功按其层级报告。完整整机从零复现尚未通过，因此不填写虚构的最终release、机械实测或全系统性能数据。七项要求的章节、附件与证据范围见requirements/coverage.json。

参考文献

[1] GE Z, LIU S, WANG F, et al. YOLOX: Exceeding YOLO Series in 2021[EB/OL]. 2021. https://arxiv.org/abs/2107.08430 .

[2] ZHANG Y, SUN P, JIANG Y, et al. ByteTrack: Multi-Object Tracking by Associating Every Detection Box[EB/OL]. 2021/2022. https://arxiv.org/abs/2110.06864 .

[3] WU W, PENG H, YU S. Yunet: A tiny millisecond-level face detector[J]. Machine Intelligence Research, 2023, 20(5): 656-665. 模型说明: https://github.com/opencv/opencv_zoo/tree/main/models/face_detection_yunet .

[4] OPENCV. OpenCV Zoo: SFace model and reference implementation[EB/OL]. https://github.com/opencv/opencv_zoo/tree/main/models/face_recognition_sface .

[5] AMD/XILINX. Vitis AI 3.0: IP and Tool Version Compatibility[EB/OL]. https://xilinx.github.io/Vitis-AI/3.0/html/docs/reference/version_compatibility.html .

[6] PYNQ PROJECT. pynq.overlay Module, PYNQ v3.1 documentation[EB/OL]. https://pynq.readthedocs.io/en/v3.1/pynq_package/pynq.overlay.html .

[7] AMD. 全国大学生嵌入式芯片与系统设计竞赛2026选题指南：自主选题赛道，3.3节[Z]. 用户本地完整指南及3.3.5.3截图。

[8] 往届验证报告[Z]. 用户提供，9个PDF页面。仅参考验证环境、流程、指标和结果的组织方式，不采用其光计算参数或得分公式。

公开算法和工具文献用于说明已有基础。项目部署、性能和完成情况由对应版本证据支持；来源路径、归档SHA及新旧证据范围见source_index.json。

附录 证据与附件导航

编号或目录	内容	使用范围
V01-V03、V20-V25	资源、时序、RTL/Tcl、引脚与时钟	对应历史联合平台
V04-V07、V19	模型身份、固定输入和质量JSON	模型路径及量化模拟，分别标注层级
V08-V10	短字段、资源短窗和自然回收	对应原版本，不拼成最新整机结果
V11、V17	旧发布状态和旧项目审查	历史快照；当前结论采用V29-V30
V12-V16、V26-V28	Skill旧验证和工程协作复盘	保留原始范围与缺项
V29-V31	新保存进度、转轴用户验收和两轮时延	文件中的原时点，不是本轮新设备查询
V32	本次Windows离线Skill验证	15单元、加法36例、CRC37例；不含板测
V33	本对话提示/答复与实际工具纠错	公开可见摘录，不冒充全部历史导出
attachments/wiring	接线PDF、PNG、SVG、逐线表与图题	资料核对版，外部接线尚待实物核对
reproduction	可执行离线入口与完整重建输入说明	离线可复现；整机前提和待验项明确

报告正文、对照图与数据表使用同一份data/metrics.json的数值，图表与正文按来源交叉核对。原始阶段证据、实际离线输出、代码和使用边界一起保留，方便复查。